

乳腺影像的分类与特征识别

2026 年 5 月 30 日

乳腺影像的分类与特征识别

2026 年 5 月 30 日

摘要

本文采用

关键词: 神经网络, 图像分类, 特征识别, BI-RADS, 多任务学习, 乳腺超声

1 实验结果可视化与分析

本文提出的多任务模型在包含 6 个 BI-RADS 等级分类和 4 项超声特征检测的验证集上进行了全面评估。模型共训练 48 个 epoch, 在第 29 个 epoch 取得最佳综合性能 (以四项特征的平均 F1 分数为选择依据), 以下所有结果均基于该最佳检查点。

1.1 核心评价指标定义

为全面衡量模型性能, 本文采用五项核心指标对模型进行多维度评估, 各指标定义如下:

- (1) **准确率 (Accuracy, ACC):** 模型对肿瘤分类 (良性或恶性) 的正确预测数占总预测数的百分比, 计算公式为:

$$ACC = \frac{TP + TN}{TP + TN + FP + FN} \quad (1)$$

其中 TP 为真阳性 (正确预测为恶性), TN 为真阴性 (正确预测为良性), FP 为假阳性 (误判为恶性), FN 为假阴性 (漏判为良性)。

- (2) **特征预测准确率 (Feature Accuracy, FEA):** 先分别计算模型对边界、钙化、形状和方向四个特征的二分类预测准确率, 再取四项结果的平均值:

$$FEA = \frac{1}{4} \sum_{i=1}^4 ACC_{\text{feature}_i} \quad (2)$$

该指标综合反映模型对四项超声特征的识别能力。

- (3) **灵敏度 (Sensitivity, SEN)**: 衡量模型正确识别恶性肿瘤的能力, 为真阳性样本数占真阳性与假阴性样本总数的比例:

$$SEN = \frac{TP}{TP + FN} \quad (3)$$

灵敏度越高, 漏诊率越低, 对临床筛查意义重大。

- (4) **特异性 (Specificity, SPE)**: 衡量模型正确识别良性肿瘤的能力, 为真阴性样本数占真阴性与假阳性样本总数的比例:

$$SPE = \frac{TN}{TN + FP} \quad (4)$$

特异性越高, 误诊率越低, 可减少不必要的穿刺活检。

- (5) **F1 分数 (F1 Score)**: 精确率 (Precision) 与召回率 (Recall) 的调和平均数, 用于评估模型在不平衡数据集上的综合性能:

$$F1 = 2 \times \frac{P \times R}{P + R}, \quad P = \frac{TP}{TP + FP}, \quad R = \frac{TP}{TP + FN} \quad (5)$$

F1 分数同时兼顾了精确率和召回率, 在不平衡数据集上比准确率更具参考价值。

1.2 模型性能指标汇总

基于最佳 epoch (第 29 轮) 的验证集结果, 模型在五项核心指标上的表现如表 1 所示。

表 1: 模型核心性能指标汇总

指标	符号	数值
准确率 (BI-RADS 6 类分类)	ACC	64.05%
特征预测准确率 (4 特征平均)	FEA	83.09%
灵敏度 (4 特征平均 Recall)	SEN	79.67%
特异性 (4 特征平均 Specificity)	SPE	83.90%
F1 分数 (4 特征平均)	F1	51.64%

各特征的具体分类性能如表 2 所示。

从表 2 可以看出:

- **钙化检测表现最优**: F1 分数达 71.63%, 精确率 (68.94%) 和召回率 (74.54%) 均处于较高水平, 反映钙化特征在超声图像中具有较好的可区分性。

表 2: 四项超声特征分类性能明细

特征	准确率	精确率	召回率	F1 分数	特异性
边界 (boundary)	80.59%	42.11%	79.28%	55.00%	80.82%
钙化 (calcification)	78.44%	68.94%	74.54%	71.63%	80.68%
形状 (shape)	78.98%	35.15%	73.96%	47.65%	79.72%
方向 (direction)	94.34%	19.61%	90.91%	32.26%	94.39%
平均	83.09%	41.45%	79.67%	51.64%	83.90%

- **方向检测存在严重假阳性问题：**召回率高达 90.91%，但精确率仅 19.61%，呈现典型的高召回-低精确模式。模型倾向于将大量阴性样本误判为阳性（假阳性），这是当前模型性能的最大瓶颈。
- **形状检测面临类似挑战：**召回率 73.96% 但精确率仅 35.15%，同样存在假阳性偏高的问题，但程度较方向检测略轻。
- **边界检测处于中等水平：**F1 分数 55.00%，精确率与召回率相对均衡。

此外，四项特征的边界框定位 IoU（仅统计正样本）在 0.46-0.49 之间，定位精度整体一致但仍有提升空间。

1.3 算法性能评分计算

1.3.1 算法性能得分 A

算法性能得分 A 由上述五项核心指标加权求和得到，权重分配如下：

$$A = 0.4 \times ACC + 0.4 \times FEA + 0.1 \times F1 + 0.05 \times SEN + 0.05 \times SPE$$

(6)

代入本模型实际数值：

$$\begin{aligned} A &= 0.4 \times 64.05\% + 0.4 \times 83.09\% + 0.1 \times 51.64\% + 0.05 \times 79.67\% + 0.05 \times 83.90\% \\ &= 25.62\% + 33.24\% + 5.16\% + 3.98\% + 4.20\% \\ &= 72.20\% \end{aligned}$$

(7)

各指标贡献分解如表 3 所示。

表 3: 算法性能得分 A 计算分解

指标	权重	数值	加权贡献
准确率 (ACC)	0.40	64.05%	25.62%
特征预测准确率 (FEA)	0.40	83.09%	33.24%
F1 分数 (F1)	0.10	51.64%	5.16%
灵敏度 (SEN)	0.05	79.67%	3.98%
特异性 (SPE)	0.05	83.90%	4.20%
合计	1.00	—	72.20%

1.3.2 运行时间得分 T

运行时间得分 T 根据所有参赛算法的运行时间集合计算，公式为：

$$T = \frac{T_{\max} - T_{\text{algo}}}{T_{\max} - T_{\min}} \times 100\% \quad (8)$$

其中：

- T_{algo} 为本算法处理整个测试集的实际运行时间；
- $T_{\max}$ 为所有参赛算法中处理测试集的最长运行时间；
- $T_{\min}$ 为所有参赛算法中处理测试集的最短运行时间。

算法处理整个测试集的时间越短,运行效率越高,该项得分也越高。本模型采用 EfficientNet-B3 骨干网络 (约 12.2M 参数), 配合 FP16 混合精度推理, 单张图像推理时间约 12–15 ms (在 NVIDIA RTX 4090 上测得), 具备良好的实时性。最终运行时间得分 T 需待所有参赛算法运行时间确定后计算。

1.3.3 综合评分 O

综合评分 O 由算法性能得分 A 与运行时间得分 T 加权求和得到：

$$O = 0.8 \times A + 0.2 \times T \quad (9)$$

在当前阶段, 假设运行时间得分 $T = 100\%$ (最佳情况):

$$O = 0.8 \times 72.20\% + 0.2 \times 100\% = 57.76\% + 20.00\% = 77.76\% \quad (10)$$

若运行时间得分 $T = 50\%$ （中等情况）：

$$O = 0.8 \times 72.20\% + 0.2 \times 50\% = 57.76\% + 10.00\% = 67.76\% \quad (11)$$

综合评分的最终确定需待运行时间得分 T 的实测数据。

1.4 训练过程损失曲线分析

图 1 展示了模型训练过程中的三条损失曲线，分别对应总损失、BI-RADS 分类损失和特征检测损失。




图 1: 训练过程损失曲线（训练集与验证集对比）

从损失曲线可以观察到：

- **总损失 (Total Loss)：** 训练与验证损失同步持续下降，二者差距较小，表明模型未出现明显的过拟合现象。
- **BI-RADS 分类损失：** 训练损失从约 0.4 平稳下降至 0.18 左右，验证损失在第 20 轮以后趋于稳定，收敛过程健康。
- **特征检测损失：** 从约 0.4 降至约 0.19，下降幅度在三项损失中最大。验证损失在第 20 轮后趋于平稳，第 48 轮因早停触发而终止训练。

1.5 BI-RADS 分类准确率分析

图 2 展示了 BI-RADS 6 类分类准确率随训练轮数的变化曲线。

分析要点：

- 训练集 Top-1 准确率稳步上升至约 74.1%，表明模型在训练数据上学习充分。




图 2: BI-RADS 分类准确率曲线（绿色虚线标注最佳 epoch）

- 验证集准确率最终达到 64.05%，绿色虚线标注了最佳 epoch（第 29 轮）的峰值位置。
- 训练与验证准确率之间存在约 10 个百分点的差距，提示存在一定程度的过拟合。可通过增加 MixUp 概率、提高标签平滑系数或进一步降低模型容量来缩小这一差距。

1.6 特征检测性能可视化

1.6.1 特征检测 IoU 曲线

图 3 展示了四项特征正样本（特征存在）边界框的交并比（IoU）随训练轮数的变化。

四项特征的 IoU 均收敛至 0.46–0.49 区间，定位精度整体一致。其中钙化（橙色）的 IoU 最高（约 0.48），方向（红色）的 IoU 略低（约 0.46）。训练初期（前 10 轮）IoU 快速提升，之后缓慢改善趋于平稳，表明检测头的定位能力已接近当前架构的上限。

1.6.2 特征分类完整指标

图 4 以 2×2 子图的形式展示了四项特征分类的精确率、召回率、F1 分数和特异性指标。关键发现：

- **精确率 (Precision):** 钙化最高（约 0.69），方向最低（约 0.20），方向检测的假阳性问题最为突出。
- **召回率 (Recall):** 方向最高（约 0.91），说明模型对方向正样本高度敏感，但精确率过低导致大量误报。




图 3: 四项特征检测 IoU 曲线 (仅统计正样本)




图 4: 特征分类完整指标: Precision / Recall / F1 / Specificity

- **F1 分数**: 钙化最优 (约 0.72), 方向最差 (约 0.33)。方向的高召回被低精确率严重拖累。
- **特异性 (Specificity)**: 四项特征均在 0.79–0.94 之间, 方向的特异性最高 (0.94), 与低精确率形成反差, 进一步证实假阳性问题的严重性。

1.6.3 特征检测 Loss 分解

图 5 展示了四项特征各自独立的分类损失 (cls loss) 与边界框损失 (bbox loss) 分解。




图 5: 特征检测 Loss 逐特征分解 (蓝线: 分类 Loss, 红线: 边界框 Loss)

从图中可以看出, 边界 (boundary) 和形状 (shape) 的分类损失收敛值相对较高, 反映了正负样本严重不平衡导致的分类困难。方向 (direction) 的分类损失最低 (约 0.005), 说明模型在此特征上分类过于偏向负样本, 这也是假阳性问题的根源。而所有特征边界框损失均在稳步下降至 0.01–0.02 之间, 定位能力持续改善。

1.6.4 检测 AP@0.5 曲线

图 6 展示了检测 AP@0.5 (类别正确且 IoU > 0.5 的检出率) 随训练轮数的变化。




图 6: 检测 AP@0.5 曲线（综合衡量分类精度与定位精度）

钙化（橙色）的 AP@0.5 最高（约 0.48），是综合分类与定位表现最优的特征。方向（红色）AP@0.5 仅约 0.36，边界（蓝色）约 0.41，形状（绿色）约 0.40。方向与形状的低 AP@0.5 主要由分类精确率过低导致，改进方向为提高 Focal Gamma 值、引入在线困难样本挖掘（OHEM）。

1.7 学习率调度与训练效率

图 7 展示了 CosineAnnealing 配合 5 轮 Linear Warmup 的学习率调度曲线。




图 7: 学习率调度曲线（Log 尺度 Y 轴）

训练采用了余弦退火（Cosine Annealing）学习率调度策略，配合 5 个 epoch 的线性预热

(Linear Warmup)。预热阶段学习率从 0 线性增长至基础学习率 3×10^{-4} ，之后沿余弦曲线平滑衰减。实际训练在第 48 轮因早停触发而终止，此时学习率约为 1.77×10^{-4} ，模型已收敛至最优解附近。

1.8 混淆矩阵

图 8 展示了四项超声特征分类的混淆矩阵，直观呈现了各特征真阳性、真阴性、假阳性、假阴性的样本分布。




图 8: 四项超声特征分类混淆矩阵

- 由混淆矩阵可以直观验证：
- **钙化**：混淆矩阵分布最为均衡，假阳性和假阴性数量均较低，与 F1 分数最高（71.63%）的结论一致。
 - **方向**：假阳性（将阴性误判为阳性）数量显著偏高，假阴性（将阳性漏判为阴性）数量很低，与精确率 19.61%、召回率 90.91% 的数据特征完全吻合。
 - **形状**：假阳性问题同样突出，但程度较方向略轻。

- **边界：**各项指标处于四者中间水平，性能相对均衡。

1.9 模型性能总结

综合以上分析，本模型在乳腺超声 BI-RADS 分类与特征检测任务上取得了初步成果，算法性能得分 $A = 72.20\%$ 。主要性能瓶颈集中在方向（direction）和形状（shape）特征的检测精确率过低（分别为 19.61% 和 35.15%），导致假阳性率偏高。